

中文电子书排版测试

—— PyMuPDF 4 LLM 提取质量验证样本

第一章 引言

这是一本用于测试的电子书。它的文字层可以直接复制，属于电子版 PDF。本书由脚本生成，用于验证 PyMuPDF 4 LLM 从 PDF 提取中文正文、标题层级、图片和脚注的能力。正文中会混入英文术语，例如 Python、PDF、EPUB，以验证中英文混排的提取效果。

第二段继续验证段落识别。中文书籍的正文排版通常采用两端对齐，段落之间通过空行或缩进区分。提取工具应当保留段落结构，而不是把整页文字压成一段。这里补充一些标点符号测试：逗号，句号。分号；冒号：括号（圆括号）【方括号】引号“双引号”和‘单引号’。

第二章 图片

本章插入两张图片，分别使用中文文件名和英文文件名，用于验证图片提取与命名处理。




图 1：中文文件名插图




图 2：英文文件名插图

第三章 脚注

脚注在学术类书籍中十分常见 [1]。本书用页脚位置的小号文字模拟脚注，用于验证提取工具是否能区分正文与脚注，并将脚注内容保留下来 [2]。

正文继续：脚注通常用上标数字标记，在页面底部给出注释内容。提取时如果能把脚注保留为可识别的结构，将有利于后续 E P U B 转换。

[1] 这是第一条脚注：脚注应当与正文区分，但内容不能丢失。

[2] 第二条脚注：欧拉 (L e o n h a r d E u l e r , 1 7 0 7 - 1 7 8 3) 是瑞士数学家。