

中文电子书排版测试

—— PyMuPDF 4 LLM 提取质量验证样本

第一章 引言

这是一本用于测试的电子书。它的文字层可以直接复制，属于电子版 PDF。本书由脚本生成，用于验证 PyMuPDF 4 LLM 从 PDF 提取中文正文、标题层级、图片和脚注的能力。正文中会混入英文术语，例如 Python、PDF、EPUB，以验证中英文混排的提取效果。

第二段继续验证段落识别。中文书籍的正文排版通常采用两端对齐，段落之间通过空行或缩进区分。提取工具应当保留段落结构，而不是把整页文字压成一段。这里补充一些标点符号测试：逗号，句号。分号；冒号：括号（圆括号）【方括号】引号“双引号”和‘单引号’。

第二章 图片

本章插入两张图片，分别使用中文文件名和英文文件名，用于验证图片提取与命名处理。




图 1：中文文件名插图




图 2：英文文件名插图

中文电子书排版测试

—— PyMuPDF 4 L L M 提取质量验证样本

第一章 引言

这是一本用于测试的电子书。它的文字层可以直接复制，属于电子版 P D F 。本书由脚本生成，用于验证 PyMuPDF 4 L L M 从 P D F 提取中文正文、标题层级、图片和脚注的能力。正文中会混入英文术语，例如 P y t h o n 、 P D F 、 E P U B ， 以验证中英文混排的提取效果。

第二段继续验证段落识别。中文书籍的正文排版通常采用两端对齐，段落之间通过空行或缩进区分。提取工具应当保留段落结构，而不是把整页文字压成一段。这里补充一些标点符号测试：逗号，句号。分号；冒号：括号（圆括号）【方括号】引号“双引号”和‘单引号’。